CLASSIFICATION DE TAGS STACK OVERFLOW

ARNAUD FRANCOISE
THIBAUD DIROU
THIBAUT DELATTRE
CYRIL DELANNOY

SOMMAIRE

- Objectif du projet
- Présentation et extraction des données
- Préprocessing
- Modèle (caractéristiques, entraînement)
- Problèmes rencontrés et axes d'amélioration (autres pistes qu'il serait possible d'explorer)

OBJECTIF

- Prédire les tags associés à une question sur le forum Stack Overflow

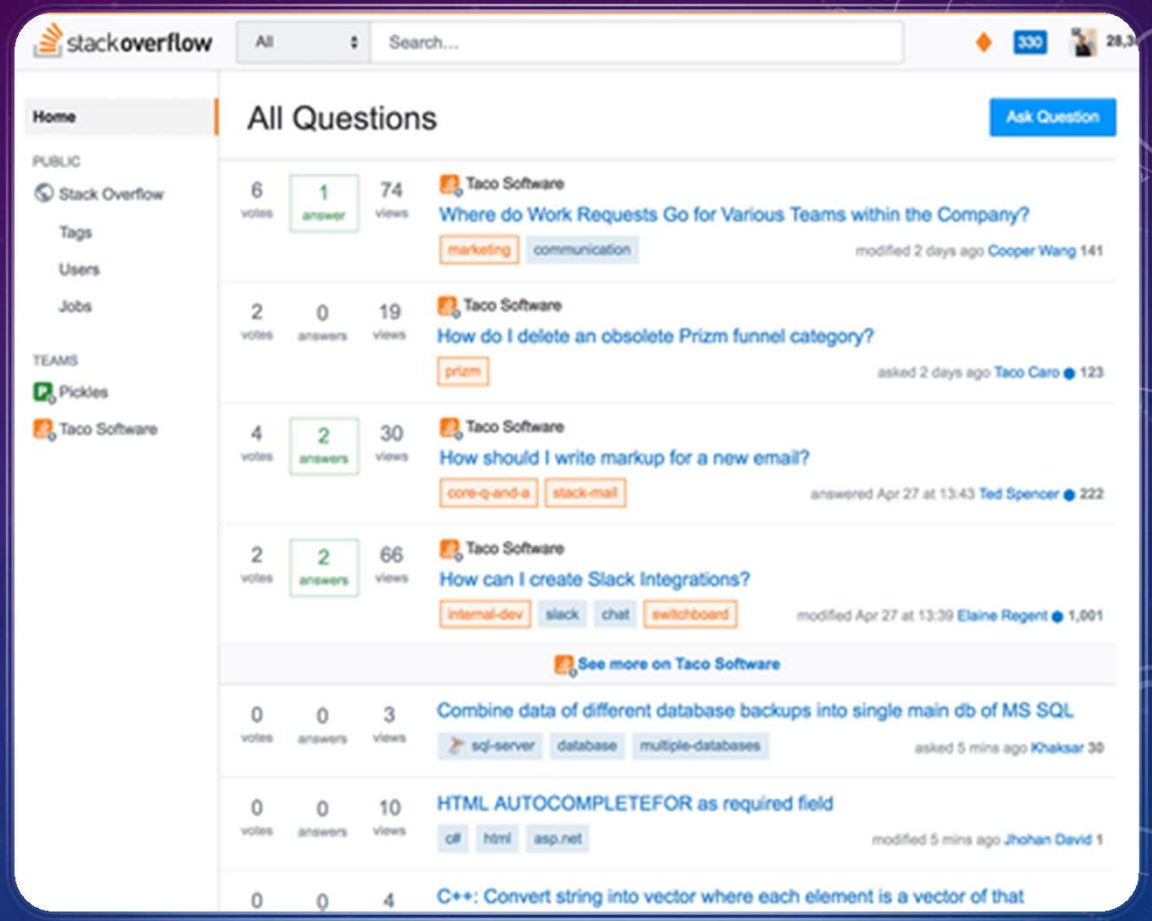

PRÉSENTATION DES DONNÉES

Qualité :

- Requêtes SQL permettant d'extraire des .csv
- Plusieurs tags par post dans la plupart des posts
- Les posts contiennent des balises html

EXTRACTION DES DONNÉES

- Choix de 26 tags principaux (Javascript, Python, Java, …)

- Extraction d'un fichier csv par tag contenant chacun 10000 posts Stack Overflow

ETAPES DE PREPROCESSING

- Suppression de la ponctuation
- Suppression des stopwords[i have pet]
- Tokenization (transformation des données sous forme de vecteurs) [I, have, a, pet]
- Lemmatization ou Stemming having -> have -> hav

TF-IDF

TF permet de mesurer l'importance relative d'un mot dans un document.

$$TF\ (i,j) = \frac{log_2(1+Freq(i,j))}{log_2(L_j)}$$

IDF mesure la signification d'un terme non pas en fonction de sa fréquence dans un document particulier, mais en fonction de sa distribution et de son utilisation dans l'ensemble des documents.

$$IDF\ (i) = log\left(\frac{N_D}{f_i} + 1\right)$$

Term Frequency – Inverse Document Frequency est une mesure qui permet, à partir d'un ensemble de textes, de connaître l'importance relative de chaque mot.

$$TF - IDF\ (i,j) = TF\ (i,j) * IDF(i)\ .$$

WORD TO SEQUENCE

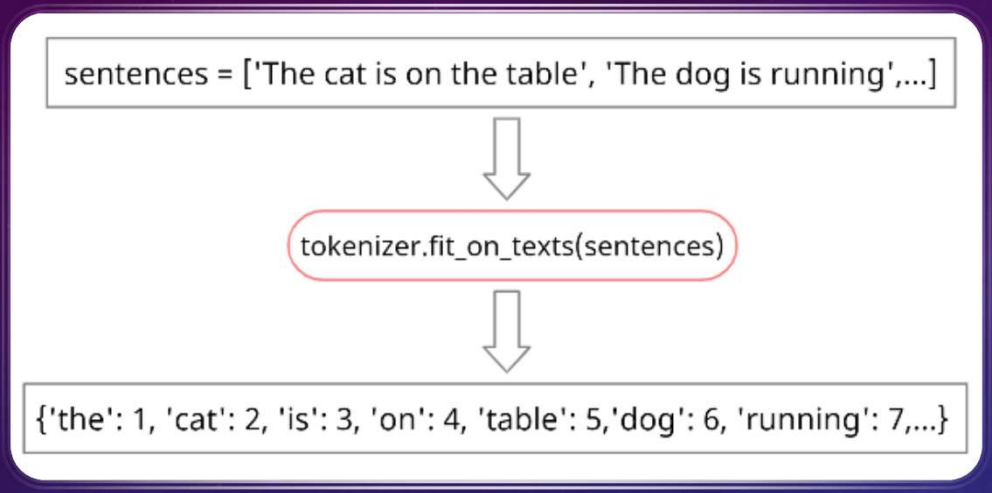

Cette méthode créé un dictionnaire dans lequel chaque mot est associé à un entier.

Plus l'entier associé est petit plus le mot est fréquent

Transforme chaque mot du texte par sa valeur associée dans le dictionnaire

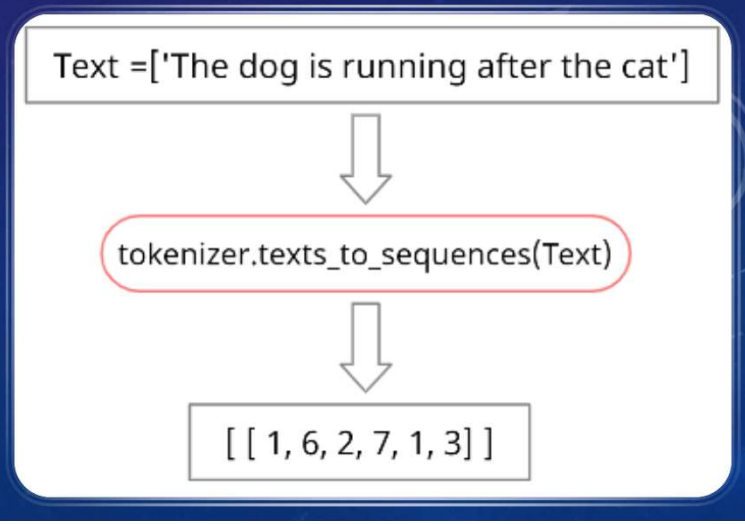

RNN

- Data:
  - 100 corpus par tags
  - Top 10 tags stackoverflow

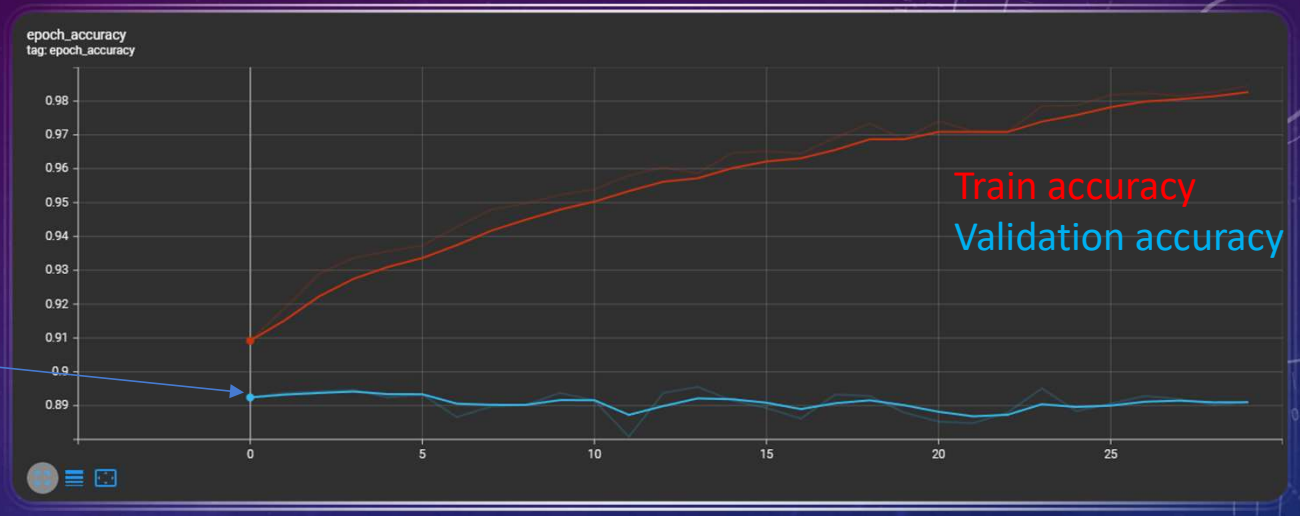

89% validation accuracy

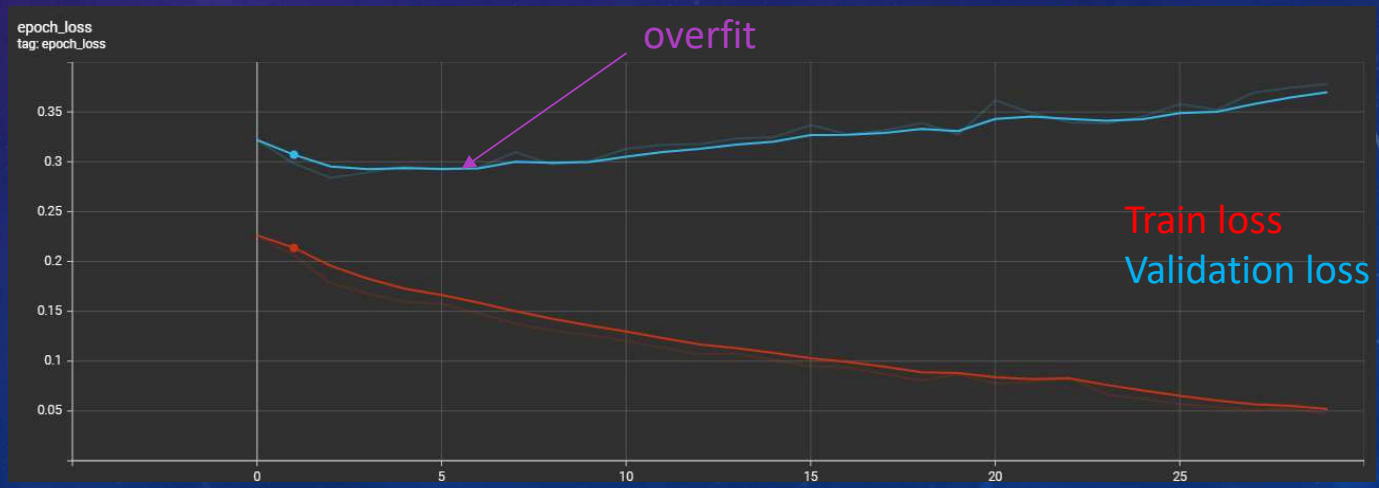

PREDICTIONS

Note pour Mr Dubreu
Ici il faut que je refasse les graphiques.
J'ai fais l'erreur de ne pas sauver ma matrice y_test qui contient les données inconnues au model désolé.
En attendant de refaire un entrainement en local (4h) ,
J'ai tracé ses graphiques sur un mix de data test et train (déjà vu)

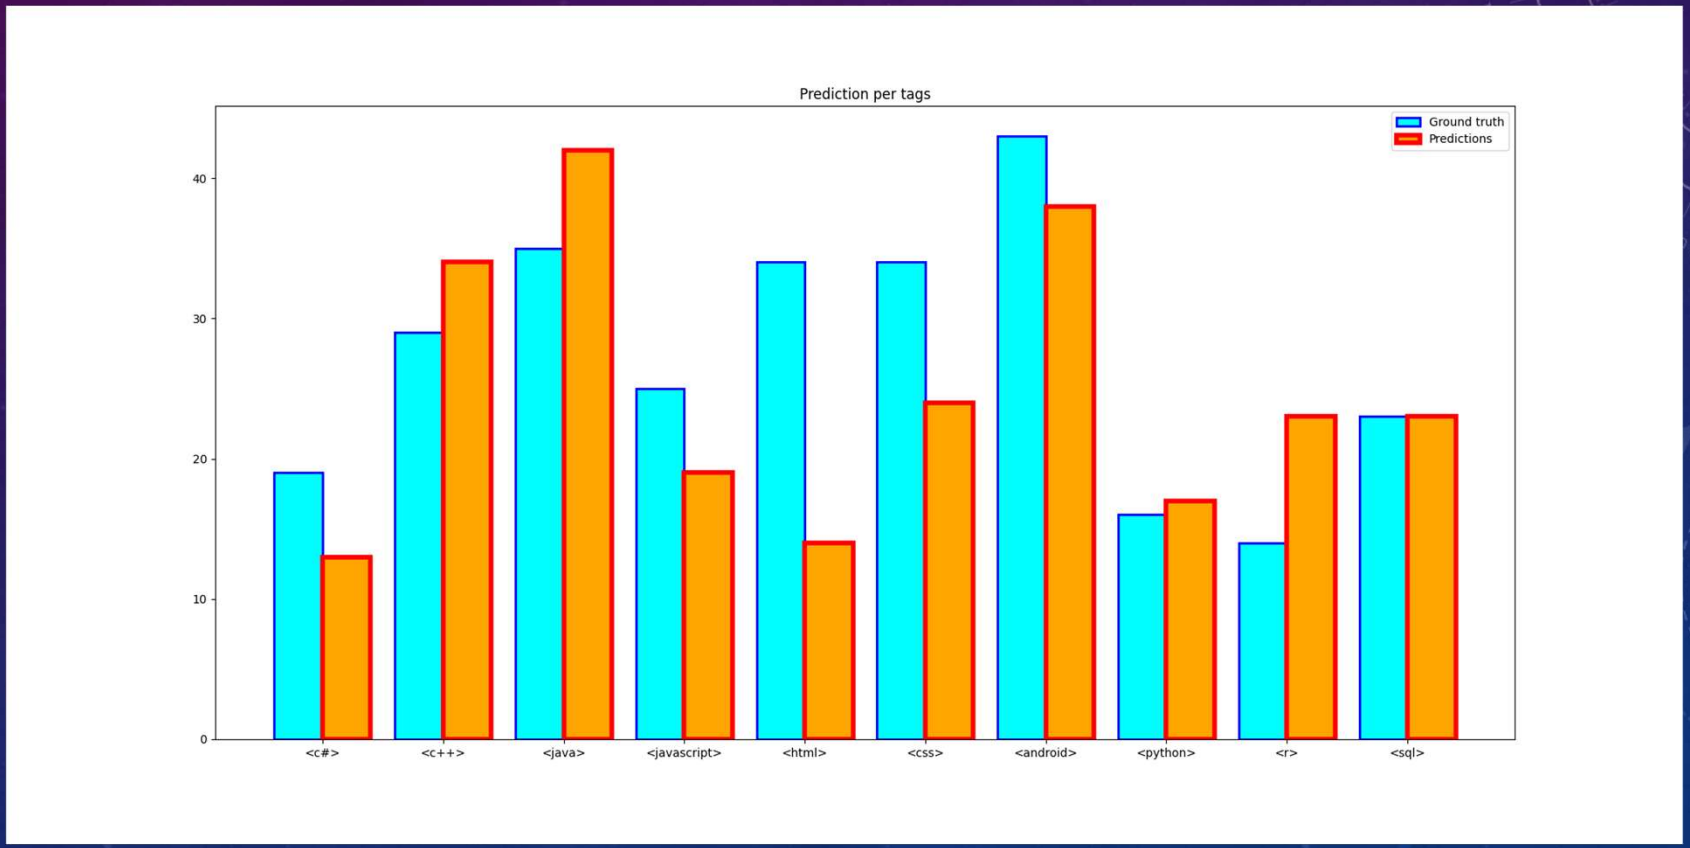

PREDICTIONS

Note pour Mr Dubreu
Ici il faut que je refasse les graphiques.
J'ai fais l'erreur de ne pas sauver ma matrice y_test qui contient les données inconnues au model désolé.
En attendant de refaire un entrainement en local (4h) ,
J'ai tracé ses graphiques sur un mix de data test et train (déjà vu)

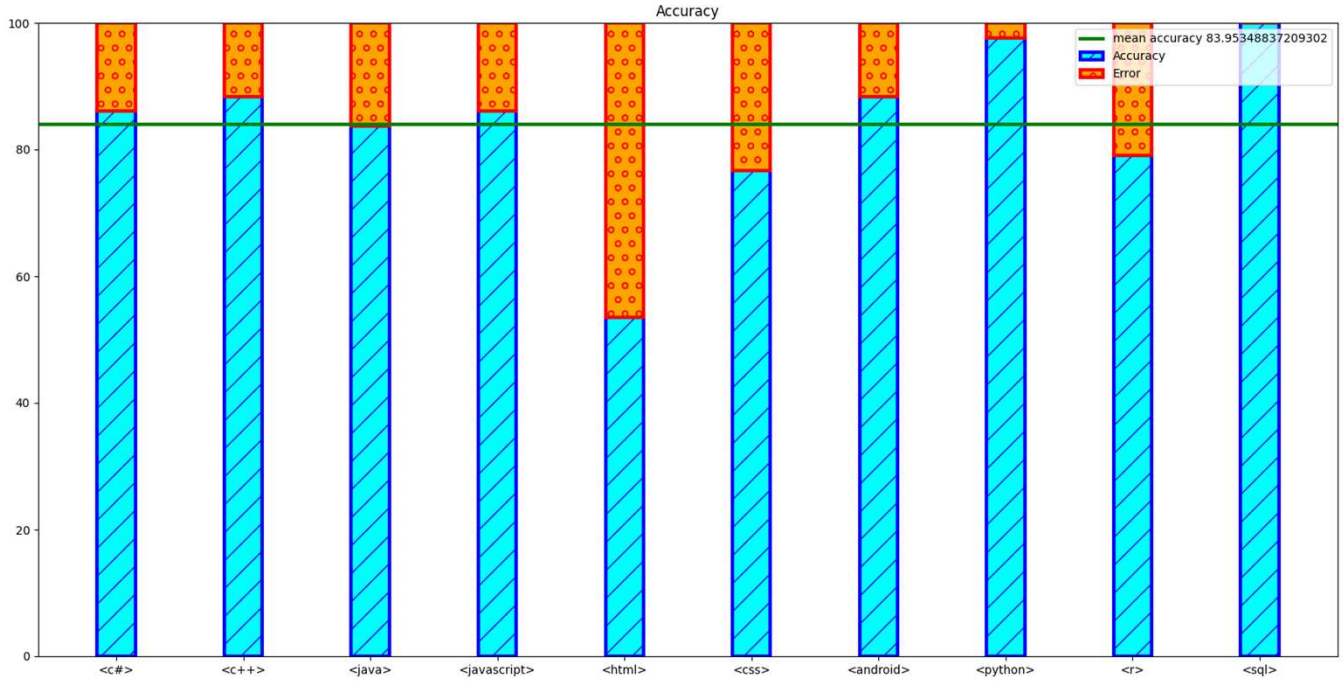

PROBLÈMES RENCONTRÉS :

- Taille du dataset trop grand.
- Entrainement du RNN très long.
- Colab limité

AXES D'AMÉLIORATION

- Augmentation du dataset
- Augmenter le nombre de tags à prédire
- Nécessite une puissance de calcul conséquente